# Fondamenti di ${\it R}$

<sub>≔</sub> Tags

# ▼ Fondamenti

I commenti in R sono preceduti da un #

```
# questo è un commento
```

Operatori matematici semplici:

```
# An addition
5 + 5
# A subtraction
5 - 5
# A multiplication
3 * 5
# A division
(5 + 5) / 2
# Exponentiation
2 ^ 5
# Modulo
28 %% 6
```

Le variabili in R sembrano essere weakly typed

```
# value 42 assigned to the x variable
x <- 42</pre>
```

Possiamo stampare il contenuto di una variabile nella console digitando una espressione senza assegnamento

```
my_apples
my_oranges + my_apples
```

R non fa una conversione implicita sommando un numeric e un text

```
# won't work
my_fruit <- 6 + "six"</pre>
```

Tipi base in R sono:

- numeric ⇒ 4.5
- integer  $\Rightarrow 4$
- logical ⇒ TRUE/FALSE
- characters ⇒ "any string"

Tramite la funzione class() è possibile controllare il tipo di una variabile

```
class(my_numeric)
# > [1] "logical"
```

La funzione summary() permette di ottenere un sommario delle informazioni contenute in una qualsiasi variabile

```
survey_vector <- c("M", "F", "F", "M", "M")
factor_survey_vector <- factor(survey_vector)
levels(factor_survey_vector) <- c("Female", "Male")

summary(survey_vector)

# Length Class Mode

# 5 character character

summary(factor_survey_vector)

# Female Male

# 2 3</pre>
```

Gli operatori di logica booleana pre-esistenti in sono:

- &: Element-wise AND
- as: Logical AND (only first element).

  Se utilizzato su vettori controlla solo il primo elemento del vettore
- | Element-wise OR
- III: Logical OR (only first element)
  Se utilizzato su vettori controlla solo il primo elemento del vettore
- NOT

La funzione runif(x, min, max) permette di generare un vettore casuale di x elementi tra min e max . se min e max non sono definiti il range di default è [0, 1]

# ▼ Strutture Dati

# **▼** Vettori

#### Creazione

In R è possibile creare un vettore tramite l'utilizzo della funzione combine c

```
my_numeric_vector <- c(3, 4, 5, 6)</pre>
```

è possibile creare un vettore come composizione di altri vettori

```
A <- c(1, 2, 3)

B <- c(4, 5, 6)

C <- c(A, B)

C

# > [1] 1 2 3 4 5 6
```

## Nomi

è possibile associare delle label(nomi) ai campi di un vettore utilizzando la funzione names().

Se i nomi associati al vettore non sono stati inizializzati, la funzione names() ritornerà NULL

```
some_vector <- c("John Doe", "poker player")
names(some_vector) <- c("Name", "Profession")</pre>
```

## Operatori

La somma tra due vettori esegue la **somma "elemento per elemento"** 

```
A <- c(1, 1, 1)
B <- c(2, 2, 2)
A + B
# > [1] 3 3 3
```

La funzione sum() permette di ritornare la somma di tutti gli elementi di un vettore

La funzione mean() la media ...

```
A <- c(1, 1, 1, 1)

sum(A)

# > [1] 4

mean(A)

# [1] 1
```

#### Indicizzazione

In R l'indicizzazione dei vettori avviene tramite le quadre [] .

# L'indicizzazione parte da 1

```
A <- c(1, 2, 3)
names(A) <- c("Primo", "Secondo", "Terzo")
A[1]
# > Primo
# 1
```

è possibile utilizzare un vettore per indicizzare un sottoinsieme di elementi del vettore

```
A <- c("A", "B", "c", "d")
A[c(1, 3, 4)]
# > A c d
```

è possibile ottenere lo stesso risultato utilizzando l'operatore di abbreviazione

```
A <- c("A", "B", "c", "d")
A[1:3]
# > A B C
```

è possibile indicizzare anche usando i nomi (se sono inizializzati per il vettore, altrimenti ritorna NA per ogni elemento)

```
A <- c(1, 2, 3)
names(A) <- c("Primo", "Secondo", "Terzo")
A[c("Primo", "Secondo")]
# > Primo Secondo
# 1 2
```

Se indicizziamo un vettore con un vettore di **logical** <u>della stessa dimensione</u>, R ritornerà solo gli elementi per il quale il logical era TRUE

```
A <- c(1, 2, 3)
A[c(TRUE, TRUE, FALSE)]
# > [1] 1 2
```

#### Confronti

è possibile usare gli operatori di confronto anche tra vettori (eseguono il confronto "elemento per elemento")

```
c(4, 5, 6) > 5
# > [1] FALSE FALSE TRUE
```

# Sorting

Per ordinare un vettore è possibile utilizzare la funzione order() che preso in input un vettore ritorna un nuovo vettore contenente il ranking di ogni elemento nel vettore originale.

Applicando il vettore ottenuto come indice è possibile ritornare il vettore originale ordinato

```
a <- c(100, 10, 1000)
order(a)
# > [1] 2 1 3

a[order(a)]
# > [1] 10 100 1000
```

Alternativamente è possibile utilizzare la funzione sort() che ordina direttamente.

```
v <- c(3, 1, 5, 2)
sorted_v <- sort(v)</pre>
```

Con il parametro decreasing è possibile ordinare il vettore in modo discendente

```
v <- c(3, 1, 5, 2)
sorted_v <- sort(v, decreasing = TRUE)
sorted_v <- v[order(v, decreasing = TRUE)]</pre>
```

# ▼ Matrici

#### Costruzione

è possibile creare una matrice utilizzando la funzione matrix().

Essa prende 3 parametri

- La collezione di elementi da inserire all'interno della matrice (un vettore)
- byrow: indica se la matrice sarà riempita per riga (TRUE) o per colonna (FALSE)
- nrow: indica il numero di righe che avrà la matrice

```
matrix(1:9, byrow = TRUE, nrow = 3)
# costruisce una matrice 3x3 riempita per riga
```

Se proviamo ad inizializzare una matrice con un numero di righe e di elementi che non matchano, R riempirà la matrice ciclando il vettore di elementi

```
# In matrix(1:10, byrow = TRUE, nrow = 3) :
# data length [10] is not a sub-multiple or multiple of the number of rows [3]
```

# Manipolazione matrice

Tramite la funzione cbind() è possibile aggiungere 1 o più colonne ad una matrice

Allo stesso modo la funzione rbind() permette di aggiungere 1 o più righe ad una matrice

```
A \leftarrow matrix(c(1,1,1,1,1,1), byrow = TRUE, nrow = 2)
B < -matrix(c(3,3,3,3,3,3), byrow = TRUE, nrow = 2)
C <- rbind(A, B)
С
      [,1] [,2] [,3]
# [1,]
         1
# [2,]
             1
                   1
      1
# [4,]
       3 3
                   3
             3
# [5,]
         3
                   3
```

#### Nomi

Tramite le funzioni colnames() e rownames() (che prendono in input dei vettori) è possibile nominare le righe e colonne di matrici

```
rownames(my_matrix) <- row_names_vector
colnames(my_matrix) <- col_names_vector</pre>
```

#### Operatori

Tramite le funzioni rowsums(), rowMeans(), ... è possibile effettuare l'operazione per tutte le celle per ogni riga e ritornare un nuovo vettore che contiene il risultato per ogni riga

```
A <- matrix(c(1,1,1,1,1,1,1,1), byrow = TRUE, nrow = 3)
rowSums(A)
# > [1] 3 3 3
```

Allo stesso modo è possibile fare la stessa operazione per le colonne con la funzione colsums(), colMeans(), ...

```
A <- matrix(c(1,1,1,1,1), byrow = TRUE, ncol = 2)
colSums(A)
# > [1] 3 3
```

è possibile eseguire tutti gli operatori primari tra matrici, ottenendo l'applicazione dell'operazione "elemento per elemento" tra mat1 e mat2.

```
A <- matrix(1:6, byrow = TRUE, nrow = 2)

B <- matrix(c(3,3,3,3,3,3), byrow = TRUE, nrow = 2)

A * B

# [,1] [,2] [,3]

# [1,] 3 6 9

# [2,] 12 15 18
```

Tramite l'operatore \*\* è possibile eseguire la classica moltiplicazione "righe per colonne" tra matrici

```
A <- matrix(1:6, byrow = TRUE, nrow = 2)

B <- matrix(c(3,3,3,3,3,3), byrow = TRUE, nrow = 3)

A %*% B

# [,1] [,2]

# [1,] 18 18

# [2,] 45 45
```

#### Indicizzazione

L'indicizzazione per le matrici è identica a quelle per i vettori, con la sola differenza che si applica su 2 dimensioni, usando quindi l'operatore [,].

Per selezionare tutti gli elementi di una riga o una colonna si omette quel parametro.

```
my_matrix[1,2] #Second element of the first row
my_matrix[1:3,2:4] #sub-matrix
my_matrix[,1] #All elements of the first column.
my_matrix[1,] #All elements of the first row
```

# **▼** Factors

I fattori sono una tipologia speciale di dati usate per contenere variabili categoriche.

Una variabile categorica può appartenere ad un insieme limitato di categorie.

R tratta le variabili continue e quelle categoriche in modo differente.

Un esempio di variabile categorica è il sesso (biologico), che è possibile limitare alle sole categorie "Maschio" e "Femmina"

#### Creazione

Per creare i fattori in R si fa uso della funzione factor() che prende in input un vettore.

Il fattore contiene internamente in campo Levels che contiene le possibili categorie del fattore

```
sex_vector <- c("Male", "Female", "Female", "Male", "Male")
factor_sex_vector <- factor(sex_vector)
factor_sex_vector
# [1] Male    Female Female Male    Male
# Levels: Female Male</pre>
```

Tramite il parametro levels è possibile esplicitare direttamente le possibili categorie del fattore, e tramite il parametro order / ordered è possibile definire se esiste una relazione d'ordine tra gli elementi (scandita dall'ordine di inserimento nel parametro levels)

```
factor_temperature_vector
# [1] High Low High Low Medium
# Levels: Low < Medium < High</pre>
```

#### Modificare il fattore

tramite la funzione levels() è possibile modificare i livelli di un fattore. I'ordine è importante

```
survey_vector <- c("M", "F", "F", "M", "M")
factor_survey_vector <- factor(survey_vector) # levels are: "F" "M"
levels(factor_survey_vector) <- c("Female", "Male")</pre>
```

#### Confronto

Non è possibile confrontare 2 valori di fattori se non è stata definita una relazione d'ordine tra i livelli.

#### Indicizzazione

Come per vettori e matrici è possibile indicizzare i valori contenuti nel vattore utilizzando l'operatore

## ▼ Data Frames

Un data frame è una variabile che ha le variabili di un dataset come colonne e i campioni come righe.

è una struttura dati che permette di manipolare dati che fanno uso di più tipi di dati assieme (es: un questionario con risposte chiuse e aperte)

#### Manipolare un data frame

Tramite le funzioni head() e tail() è possibile stampare il priomo/ultimo campione di un data frame in aggiunta ad una riga che contiene gli "headers"

La funzione str() permette di ispezionare la struttura di un data frame, fornendo informazioni del tipo:

- Numero di campioni (e.g. 32 car types)
- Numero totale di variabili (e.g. 11 car features)
- Lista dei nomi delle variabili (e.g. mpg , cyl ...)
- Il tipo di ogni variabile (e.g. num)
- · I primi campioni

# Creazione

Tramite la funzione data.frame() è possibile creare un nuovo data frame che utilizza come colonne (e relativi valori delle celle) i vettori passati in input

### Indicizzazione

Per indicizzare un data frame utilizziamo le stesse tecniche ed operatore delle matrici

é inoltre possibile utilizzare l'operatore 😮 per selezionare un'intera colonna per nome in rapidità

```
planets_df$diameter
# è equivalente a planets_df[,3] oppure planets_df[,"diameter"]
```

tramite la funzione subset() è possibile mostrare una proiezione del data frame applicando dei filtri (una espressione o un vettore di logical) che selezionano una porzione dei campioni

```
subset(planets_df, subset = rings)
subset(planets_df, subset = diameter < 1)
subset(planets_df, subset = (diameter < 1 & rotation > 1))
```

## ▼ Liste

In R le liste sono delle collezioni multi-tipo che possono contenere qualsiasi elemento (*numeri*, *vettori*, *matrici*, *data frames*, ...)

#### Creazione

Per creare una lista si fa uso della funzione (list()) che prende come input gli elementi da inserire nella lista

#### Nomi

è possibile nominare i componenti di una lista facendo uso della funzione names() oppure assegnando una label direttamente durante la creazione

# Indicizzazione

Si utilizza l'operatore [[]] per recuperare un elemento da una lista, oppure s se i campi hanno un nome.

# ▼ Date

In R le date sono gestite tramite oggetti di tipo Date mentre il tempo con oggetti di tipo POSIXCT

- Date gestisce le date come il numero di giorni passati dal 1 gennaio 1970
- POSIXCE gestisce il tempo come il numero di secondi passati dal 1 gennaio 1970

Per ottenere il giorno corrente facciamo uso di sys e il metodo Date(). Allo stesso modo usiamo sys.time() per ottenere il tempo attuale

```
today <- Sys.Date()
now <- Sys.time()</pre>
```

#### Creazione e formato date

Per creare una data da una stringa è possibile usare il cast as.Date() passandogli la stringa e il formato tramite il parametro format

I parametri utilizzabili per il formato sono:

- %Y: 4-digit year (1982)
- %y: 2-digit year (82)
- %m: 2-digit month (01)
- %d: 2-digit day of the month (13)
- %A: weekday (Wednesday)
- %a: abbreviated weekday (Wed)
- %B: month (January)
- %b: abbreviated month (Jan)

```
as.Date("1982-01-13") #il formto di default è "%Y-%m-%d" o "%Y/%m/%d"
as.Date("Jan-13-82", format = "%b-%d-%y")
as.Date("13 January, 1982", format = "%d %B, %Y")
```

Invece per ottenere una stringa equivalente da una data facciamo uso del metodo format()

```
today <- Sys.Date()
format(Sys.Date(), format = "%d %B, %Y")
format(Sys.Date(), format = "Today is a %A!")</pre>
```

# Creazione e formato tempi

Per creare un tempo da una stringa è possibile usare il cast as.Posixct() passandogli la stringa e il formato tramite il parametro format

I parametri utilizzabili per il formato sono:

- %H: hours as a decimal number (00-23)
- %I: hours as a decimal number (01-12)
- minutes as a decimal number
- %s: seconds as a decimal number
- %T: shorthand notation for the typical format %H:%M:%S
- %p: AM/PM indicator

```
time1 <- as.POSIXct(str1, format = "%B %d, '%y hours:%H minutes:%M seconds:%S")
time2 <- as.POSIXct(str2, format = "%Y-%m-%d %H:%M:%S")</pre>
```

Invece per ottenere una stringa equivalente da un tempo facciamo uso del metodo format()

```
time <- Sys.time()
format(time, "%M")
format(time, "%I:%M %p")</pre>
```

# Operazioni su date e tempi

Sia per Date che per POSIXCT R esegue le operazioni usando la rappresentazione numerica intrinseca dell'oggetto. Questo rende la loro manipolazione molto semplice e permette l'uso di operatori matematici

# **▼** Objects

Gli oggetti in R possono essere rappresentati da vectors o da NULL.



In realtà tutte le strutture dati in R vengono rappresentate da vector o da NULL

Gli oggetti sono quindi dei vettori che hanno delle classi aggiuntive (controllabili utilizzando la funzione unclass() e class())

```
tbl <- tibble::tibble()
class(tbl)
# [1] "tbl_df" "tbl" "data.frame"</pre>
```

Le classi sono in una relazione di ereditarietà da sinistra verso destra. ("tbl" è una sottoclasse di "data.frame")

#### Creazione

Quelle che generalmente chiamiamo oggetti, in R sono gli oggetti S3 e S4.

# S3

Sono semplici strutture dati già descritte in precedenza, ad esempio una lista, al quale andiamo a dare dei nomi ai valori e aggiungiamo una classe "custom".

```
s3 <- list(name = "John", age = 21, GPA = 3.5)
#Classe custom aggiunta
class(s3) <- "student"</pre>
```

è possibile definire un **costruttore** creando una funzione con lo stesso nome della classe che abbiamo creato. (è più che altro una convenzione)

```
student <- function(n, a, g) {
   if (g > 4 || g < 0) stop("GPA must be between 0 and 4")
   value <- list(name = n, age = g, GPA = g)
   # la classe puù essere assegnata usando class() o attr()
   attr(value, "class") <- "student"
   value</pre>
```

```
paul <- student("Paul", 26, 3.2)</pre>
```

#### **S4**

è un modo per creare una struttura dati più robusta e riutilizzabile, un template per creare oggetti di quella classe (ciò che negli HLPL convenzionali chiamiamo classi)

Usiamo la funzione setclass() per creare la classe. Il parametro slots è una lista nel quale possiamo definire quali campi appartengano alla classe

Tramite la funzione new() è possibile creare oggetti di una determinata classe predefinita

```
s4 <- new("student", name="John", age=21, GPA=3.5)
s4
```

Tramite la funzione iss4() è possibile capire con che tipo di classi stiamo lavorando su un determinato oggetto

## Indicizzazione

Per accedere al contenuto di un campo in un oggetto di tipo S4 si usa l'operatore al alternativamente si può fare uso della funzione slot()

```
s4@GPA
s4@GPA <- 3.1
slot(s4, "GPA") <- 2.9
```

#### Metodi

Tramite la funzione showMethods() è possibile identificare quali funzioni sono definite per una determinata classe.

iss4() può essere utilizzato anche sulle funzioni per capire se sono state definite per oggetti di tipo S4

## ▼ Loops

#### While

Il loop while valuta una condizione booleana e termina quando la condizione diventa FALSE

```
speed <- 64
while (speed > 30) {
  print("Slow down!")
  speed <- speed - 7
}</pre>
```

Tramite la keyword <u>break</u> è possibile terminare il loop in modo anticipato. Tramite <u>next</u> è possibile andare direttamente alla prossima iterazione.

# For

Ci sono due possibili sintassi per il for loop in R

```
# loop version 1
for (p in primes) {
   print(p)
}

# loop version 2
for (i in 1:length(primes)) {
   print(primes[i])
}
```

la funzione length() permette di ottenere la dimensione di una collezione

# ▼ Funzioni

R ha al suo interno molte funzioni di base, su queste è possibile ottenere un link alla documentazione direttamente all'interno del linguaggio tramite l'utilizzo della funzione help() o dell'operatore ?

```
help(sample)
#oppure
?sample
```

La funzione args() invece permette di vedere velocemente gli argomenti di una funzione

```
args(sample)
```

#### Creazione di una funzione

Creare una funzione in R equivale ad assegnare un oggetto funzione ad una variabile. Dopo l'assegnamento la funzione sarà presente nel workspace e sarà richiamabile come tale.

```
my_fun <- function(arg1, arg2=default) {
   body
}

pow_two <- function(number) {
    number * number
}

pow_two(12)

sum_abs <- function(arg1, arg2) {
    abs(arg1) + abs(arg2)
}

sum_abs(-2, 3)

throw_dice <- function() {
   sample(1:6, size = 1)
}
throw_dice()</pre>
```

Le funzioni in R passano i propri argomenti per valore

Non è necessario definire un return type (*è weakly typed*). Per ritornare un valore si fa uso della funzione return() oppure lasciando come ultima riga la visualizzazione di un valore.

```
interpret <- function(num_views) {
  print("You're popular!")
  return(num_views)</pre>
```

```
interpret <- function(num_views) {
  print("You're popular!")
  num_views
}</pre>
```

# ▼ Pacchetti R

Essenzialmente ci sono 2 funzioni importanti per utilizzare i pacchetti in R:

• install.packages(), installa un determinato pacchetto (ha bisogno dei permessi da admin)

```
install.packages("ggplot2")
```

• library(), carica i pacchetti allegandoli alla "search list" del workspace R.

```
library("ggplot2")
```

Tramite la funzione search() è possibile controllare quali pacchetti R sono installati localmente

library() interrompe l'esecuzione se il pacchetto non è installato mentre la funzione require() ritorna TRUE se è riuscito a caricare il pacchetto, FALSE altrimenti

```
if (!require("BiocManager", quietly = TRUE))
  install.packages("BiocManager")
```

# **▼** Apply functions

Le funzioni <u>lapply()</u>, <u>sapply()</u> e <u>vapply()</u> sono implementazioni di operatori funzionali che permettono di applicare una determinata funzione ad una collezione.

```
lapply(x, FUN, ...)
```

La funzione lapply (map in java, Select in c#) prende una collezione x e applica la funzione FUN a tutti i suoi elementi. Se FUN richiede ulteriori argomenti, vengono passati dopo FUN (...). L'output è una lista della stessa dimensione di x, dove ogni elemento è il risultato di FUN(x[1]).

```
# The vector pioneers has already been created for you
pioneers <- c("GAUSS:1777", "BAYES:1702", "PASCAL:1623", "PEARSON:1857")
# Split names from birth year
split_math <- strsplit(pioneers, split = ":")
# Convert to lowercase strings: split_low
split_low <- lapply(split_math, tolower)
# Take a look at the structure of split_low
str(split_low)</pre>
```

Come in tutti gli altri linguaggi è possibile passare come argomento anche funzioni anonime e non solo funzioni già definite nel workspace

```
names <- lapply(split_low, function(x) { x[1] })
years <- lapply(split_low, function(x) { x[2] })</pre>
```

Quando sono presenti ulteriori argomenti vengono assegnati, usando la nomeclatura esplicita, dopo la funzione

```
select_el <- function(x, index) { x[index] }
names <- lapply(split_low, select_el, index = 1)</pre>
```

```
years <- lapply(split_low, function(x, index) { x[index] }, index = 2)</pre>
```

```
sapply(x, FUN, ...)
```

Funziona come <u>lapply()</u> ma cerca di semplificare la struttura dati ritornata, se possibile la trasforma in un vettore o matrice, altrimenti ritorna una lista.

```
vapply(x, FUN, FUN.VALUE, ..., USE.NAMES = TRUE)
```

Funziona come sapply() ma l'argomento fun.value si aspetta un template per il valore di ritorno di fun. use.names prova a generare un array di nomi se possibile.

Nei casi in cui l'output generato non matchi la struttura passata tramite il parametro FUN. VALUE la funzione genera un errore.

```
basics <- function(x) { c(min=min(x), mean=mean(x), median=median(x), max=max(x)) } vapply(temp, basics, numeric(4))
```

vapply risulta una versione più robusta di sapply che limita la struttura del risultato, è in generale preferibile (in quanto maggiormente deterministica) a sapply

## ▼ Utilities functions

- <a href="mailto:absolute">abs()</a>: Calculate the absolute value.
- sum(): Calculate the sum of all the values in a data structure.
- mean(): Calculate the arithmetic mean.
- round(): Round the values to 0 decimal places by default. Try out round in the console for variations of round() and ways to change the number of digits to round to.
- seq(): Generate sequences, by specifying the from, to, and by arguments.
- rep(): Replicate elements of vectors and lists.
- sort(): Sort a vector in ascending order. Works on numerics, but also on character strings and logicals.
- rev(): Reverse the elements in a data structures for which reversal is defined.
- str(): Display the structure of any R object.
- append(): Merge vectors or lists.
- is.\*(): Check for the class of an R object.
- as.\*(): Convert an R object from one class to another.
- unlist(): Flatten (possibly embedded) lists to produce a vector.
- grep1(), which returns TRUE when a pattern is found in the corresponding character string.
- grep(), which returns a vector of indices of the character strings that contains the pattern.
- sub()
- gsub() come grep ma permettono di sostituire i match con una stringa passata al parametro replacement